DeViSE - 讲者 A

逐页中文演讲稿 · 第 1-9 页 · 每人 15:00

分工与计时

本稿由讲者 A 使用，主题：研究问题、模型与推断。 A 负责第 1-9 页，B 负责第 10-19 页，第 20 页为共用参考页。

个人计时 00:00-15:00：正文目标 14:30，缓冲 00:30。 全场排练基准为 00:00-15:00；A 可提前交接，B 接棒时将个人计时归零，不必等满第 15 分钟。

- 中英文是两个可选版本。正式演讲选一种语言；两人使用一致语言，本稿不要求重复讲两遍。

- 视频合计 40 秒、互动、45 秒排序演示或 20 秒候选切换（如适用）、停顿与交接均已计入。视频只播一次，播放时不重复朗读录制旁白。

- 方括号内为操作提示，不朗读。每个互动问题只收一个简短回答；演示时照稿讲解，不额外扩展预设。

- 英文按每分钟 110 个词估算；中文按每分钟 200 个等效单位估算，外文与数字加算时间。时间为排练规划，请按每页累计节点试讲。

- 若到 14:30 仍未收束，A 直接说交接语，B 使用下方的简短结语；略过追加互动，不重播视频，并在个人 15:00 前结束。第 20 页与问答均在两人演讲之后使用。

14:30 应急收束 - 仅在进度落后时替换剩余内容，不追加朗读：

方法部分就介绍到这里。下面交给我的搭档，继续分析实验证据。

页码与标题	个人时间	全场基准	视频
1. 模型能认出从未见过的类别吗？	00:00-01:15	00:00-01:15	0s
2. 没有训练图片，不等于没有信息	01:15-02:30	01:15-02:30	0s
3. 连接图像与词语的研究缺口	02:30-03:45	02:30-03:45	0s
4. 两个预训练模型，一个语义接口	03:45-05:25	03:45-05:25	20s
5. 语义结构从哪里来	05:25-07:40	05:25-07:40	20s
6. 不仅靠近正确标签，还要排在错误标签之前	07:40-09:20	07:40-09:20	0s
7. 训练时哪些参数会更新？	09:20-10:35	09:20-10:35	0s
8. 逐步检查一次排序更新	10:35-12:35	10:35-12:35	0s
9. 候选词表会改变答案	12:35-14:30	12:35-14:30	0s

个人 14:30-15:00 仅作缓冲，已包含在 15 分钟限时内。

1. 模型能认出从未见过的类别吗？

流程时间：个人 00:00-01:15；全场基准 00:00-01:15。 讲者 A。视频 0 秒，互动或演示 5 秒，停顿与换页 4 秒，均已计入。

大家好，今天我们两人一起介绍 DeViSE：怎样把视觉识别和语言中学到的含义连接起来。我先解释模型怎样工作、怎样预测，再由我的搭档分析实验证据与局限。

先想一个问题。假设一个分类器学会了认狗，但输出层里根本没有“鲨鱼”这个标签，它还能把一张图片叫作鲨鱼吗？识别一张新照片，和识别一个新类别，是两回事。

互动问题: 固定的 softmax 输出层，能预测一个不在输出列表里的标签吗？

DeViSE 尝试借助文本跨过这道鸿沟。要理解它怎么做，我们先得说清楚：“未见”究竟指什么。

依据： Frome et al. (2013), p.1

2. 没有训练图片，不等于没有信息

流程时间：个人 01:15-02:30；全场基准 01:15-02:30。 讲者 A。视频 0 秒，互动或演示 5 秒，停顿与换页 4 秒，均已计入。

在这篇论文里，未见类别是指视觉模型没有该类的有标注训练图像。这不等于系统对它一无所知；类别名称仍然可能出现在语言模型使用的文本里。

例如，视觉模型见过某些鲨鱼种类，而文本为另一种鲨鱼提供了词向量。目标就是把有用的结构迁移过去。

这里还要分清两个集合：接受测试的图像，和允许作为答案的标签。把已见标签加入候选答案，并不会改变测试图像。

互动问题: 对于未见类别，系统还可以获得什么信息？

明确这个设置之后，我们再看，早期方法还缺少哪一环。

依据： Frome et al. (2013), p.2

3. 连接图像与词语的研究缺口

流程时间：个人 02:30-03:45；全场基准 02:30-03:45。 讲者 A。视频 0 秒，互动或演示 5 秒，停顿与换页 4 秒，均已计入。

当时，主要的构件已经存在：卷积网络能学习有用的视觉特征，语言模型也能把含义相关的词放在相近的位置。难点是把两者连接起来，并让这种连接适用于大得多的标签词表。

这就是论文的贡献：把预训练视觉特征、从文本得到的标签表示和排序目标结合起来，做到 ImageNet 的规模。作者用一千个视觉类别训练，再研究向大约两万个额外标签迁移。

多项设计同时发生了变化，所以应评价整套方法，不能把所有改善都归因于规模。

互动问题: 语义标签表示带来了什么，是单纯扩大 softmax 不能提供的？

接下来，我们沿着信息流看一遍模型。

依据： Frome et al. (2013), p.2

4. 两个预训练模型，一个语义接口

流程时间：个人 03:45-05:25；全场基准 03:45-05:25。 讲者 A。视频 20 秒，互动或演示 5 秒，停顿与换页 4 秒，均已计入。

播放前 · 演讲者说：

先用二十秒抓住整体思路。请留意图像怎样从视觉特征进入一个与标签含义共享的空间。然后，我们再回到作者的原图，检查具体细节。

播放提示 · DeViSE 总览 · 中文 · 20 秒：

播放一次中文总览视频。等录制旁白完整结束，再继续讲解。

播放视频（20 秒）

字幕

视频旁白 · 已录制，请勿重复朗读：

没有斑马训练图，也能认出斑马吗？先用文本学词向量，用图片训练视觉网络。再把图像投影到语义空间，让正确标签得分更高。预测时比较标签得分，也能选择未见类别。前提是，已有它的词向量。

播放后 · 演讲者说：

关键的一步，是把固定输出类别的分类，改成图像向量与候选标签向量之间的比较。文本提供标签表示，训练图像教会视觉映射。只要有对应嵌入，新标签就能加入比较。这为零样本识别提供了一条路径，但不保证预测一定正确。

互动问题: 哪个部分把视觉特征连接到标签空间？

衔接 Figure 1 · 演讲者说：

刚才是整体思路。现在看原始 Figure 1，弄清两种表示从哪里来，以及模型到底学习了什么。

依据： Frome et al. (2013), p.3

5. 语义结构从哪里来

流程时间：个人 05:25-07:40；全场基准 05:25-07:40。 讲者 A。视频 20 秒，互动或演示 8 秒，停顿与换页 4 秒，均已计入。

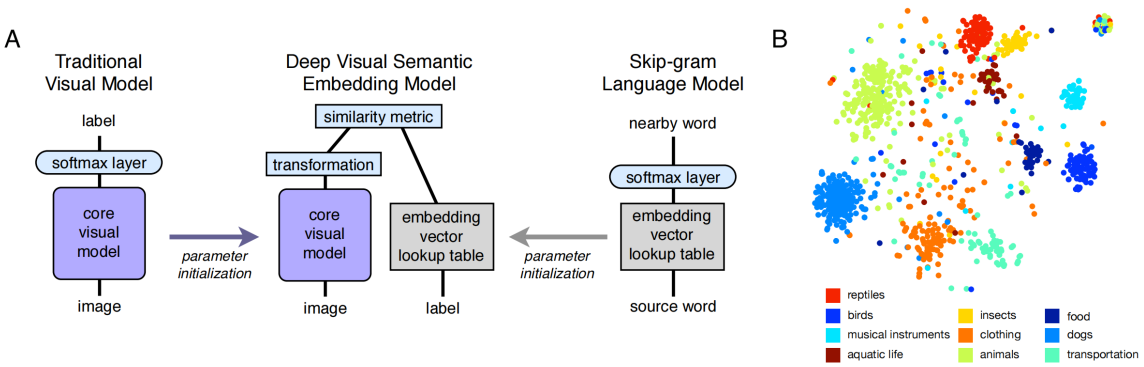


Figure 1: (a) Left: a visual object categorization network with a softmax output layer; Right: a skip-gram language model; Center: our joint model, which is initialized with parameters pre-trained at the lower layers of the other two models. (b) t-SNE visualization [19] of a subset of the ILSVRC 2012 1K label embeddings learned using skip-gram.

原论文 Figure 1 - Frome et al., NIPS 2013

查看原论文页码 3

播放前 · 演讲者说：

Figure 1 有两个面板。接下来这段短片里，请跟着两个预训练模型进入联合系统，再看看 B 图中不同颜色的语义邻域。

播放提示 · Figure 1 · 中文 · 20 秒：

播放一次 Figure 1 中文视频，结束后再继续讲解。

播放视频（20 秒）

字幕

视频旁白 · 已录制，请勿重复朗读：

DeViSE 如何连接视觉与语言？ 它结合预训练视觉网络，与固定的词向量。 学习一个投影，让图像对齐标签向量。 B 图展示标签之间的语义邻域，不是图像预测结果。

播放后 · 演讲者说：

A 图展示架构。指向中间的箭头表示参数初始化。视觉 softmax 被移除，学习到的投影把视觉特征映射到标签空间。视觉特征有四千零九十六维；论文使用五百维或一千维的标签嵌入。

B 图展示的是另一件事：用 t-SNE 可视化从文本学到的标签嵌入。在图像训练对齐两种模态之前，相关标签就已经形成邻域。这些点是标签，不是测试图像的预测；二维距离也不是分类分数。

词向量归一化后保持固定。先学习投影，再微调视觉网络。继续之前，我们先确认各部分的角色。

互动问题: B 图中的点是标签还是测试图像？图上的距离是预测分数吗？

衔接排序损失 · 演讲者说：

现在有了参照空间。怎样让图像更偏向正确标签，而不是竞争标签？这就是排序损失要解决的问题。

依据： Original Figure 1 and §3.1-3.3, p.3

6. 不仅靠近正确标签，还要排在错误标签之前

流程时间：个人 07:40-09:20；全场基准 07:40-09:20。 讲者 A。视频 0 秒，互动或演示 10 秒，停顿与换页 4 秒，均已计入。

这个目标关心的是先后顺序。我们希望正确标签的分数，比竞争标签至少高出一个小的间隔。

把铰链损失这一项读出来，就是：要求的间隔，减去正确标签分数，再加上竞争标签分数。如果正确标签已经充分领先，损失就是零；否则，这一对标签会产生学习信号。

做个简单计算：间隔是零点一，正确分数是零点六，竞争分数是零点五五，损失就是零点零五。正确标签虽然领先，但领先得还不够。

公式一写成求和；实际算法会抽取竞争标签，在第一个违反间隔的标签处停止，而不是每次更新都检查所有标签。

互动问题: 正确标签已经得分更高，为什么损失仍然大于零？

目标已经清楚了。接下来看看，它会改变模型的哪些部分。

依据： Frome et al. (2013), p.4

7. 训练时哪些参数会更新？

流程时间：个人 09:20-10:35；全场基准 09:20-10:35。 讲者 A。视频 0 秒，互动或演示 5 秒，停顿与换页 4 秒，均已计入。

预训练给模型一个起点，并不意味着所有部分都保持冻结。

作者先训练投影矩阵 M，再微调视觉网络，同时固定语言嵌入。论文采用异步随机梯度下降，并使用 Adagrad 学习率。

我们的教学示例刻意缩小了问题：固定二维视觉特征，只用普通梯度下降更新 M。这样能单独检查一个排序约束的影响，而不是假装复现完整的 ImageNet 训练。

互动问题: 视觉网络在整个训练过程中都保持冻结吗？

明确这个简化之后，我们走一遍更新，看看分数差是否按预期改变。

依据： Frome et al. (2013), p.4

8. 逐步检查一次排序更新

流程时间：个人 10:35-12:35；全场基准 10:35-12:35。 讲者 A。视频 0 秒，互动或演示 45 秒，停顿与换页 4 秒，均已计入。

现在看这个可计算的小示例。图像特征和标签向量都固定，只有投影发生变化。开始之前，先预测一下：正确分数与竞争分数之间的差距会怎样变化？

[演示提示 · 共 45 秒，含观众回答。间隔和学习率都设为 0.1；前进一步，查看分数差，再倒退，最后试一次零学习率。跳过额外预设和可选语义滑尺。]

这次有效更新后，分数差增大，损失下降。倒退可以恢复相同状态。把学习率设为零，模型就不变，说明结果确实由更新驱动。

这只是教学问题里的一个约束，不能证明真实训练中的每个样本每一步都会改善。这里的相似度分数也不是概率。

互动问题: 一次有效更新后，正确标签与竞争标签的分数差应该怎样变化？

我们看过学习怎样改变分数了。那么，如果分数不变，只改变可选答案，会发生什么？

依据： Teaching derivation from Eq.1, p.4; computed toy, not a reported experiment

9. 候选词表会改变答案

流程时间：个人 12:35-14:30；全场基准 12:35-14:30。 讲者 A。视频 0 秒，互动或演示 20 秒，停顿与换页 4 秒，均已计入。

保持图像向量不变，只改变候选列表。只有未见标签时，未见的鲨鱼标签获胜；让一个相近的已见鲨鱼标签参加竞争，第一名就可能换成这个熟悉标签。

[演示提示 · 共 20 秒，含观众回答。只切换一次“加入已见候选”，保持查询角度不变。]

这里没有重新训练。DeViSE-0 和 DeViSE+1K 表示同一个训练模型使用不同候选集合；两种设置都测试未见类别的图像。

当标签向量为单位长度、查询向量固定且非零时，点积与余弦的排序一致，但数值和固定间隔损失不一定相同。

互动问题: 加入已见候选时，模型权重改变了吗？

交接给讲者 B · 演讲者说：

我们已经看过 DeViSE 怎样做出预测。接下来要问的是：它表现怎样，又是在什么条件下成立？下面由我的搭档继续分析评估设置与实验结果。

依据： Frome et al. (2013), p.6

20. 来源、证据与可复算说明

参考页，不计入限时演讲。 两人共用，不逐项朗读。

[参考页 · 不计入限时演讲。不逐项朗读；留待单独的问答环节使用。]

下载区提供原文、官方补充材料、阅读指南和视频素材。报告结果注明论文来源；互动计算是教学示例。这里没有复现原始 ImageNet 训练。

参考提问: 哪些证据来自论文，哪些来自教学示例？

依据： Frome et al. (2013), p.1

问答准备 - 备用，不计入个人 15 分钟

两人演讲结束后再进入问答；以下为建议主答分工，另一位可以补充。

1. 文本出现过类名，为什么仍是零样本？

零样本相对于这些类别的视觉训练样本定义；语义辅助信息是明确允许的。

依据： §4.2, p.6

2. 原文联合训练会更新词向量吗？

原文固定词向量。脚注讨论同时训练语言模型的可能性，不是已报告流程。

依据： §3.3, p.4, footnote 5

3. 视觉骨干一直冻结吗？

不是。先训练 M，再微调视觉网络。

依据： §3.3, p.4

4. 为什么用排序损失而不是 L2？

预测依赖排序。Hinge 明确惩罚过于接近或超过正确标签的错误标签。论文报告 L2 较差，但不构成普遍保证。

依据： §3.3, p.4

5. 点积和余弦完全相同吗？

单位标签向量与固定非零查询下，排序相同；数值相差查询模长，固定间隔损失不一定相同。

依据： §3.3 + algebraic deduction

6. 相似度分数是概率吗？

不是。教学例子和论文目标使用点积分数，没有建立概率校准。

依据： Eq.1, p.4

7. DeViSE-0 和 +1K 是不同训练模型吗？

不是。是同一个训练模型，候选标签集合不同。

依据： Table 2 caption, p.6

11. 随机嵌入基线控制什么？

它移除学习到的标签语义结构、保留嵌入模型形式，支持语义有效，但不完美隔离全部混杂因素。

依据： §4 and Table 1