DeViSE - 讲者 B

逐页中文演讲稿 · 第 10-19 页 · 每人 15:00

分工与计时

本稿由讲者 B 使用，主题：评估、结果与批判性讨论。 A 负责第 1-9 页，B 负责第 10-19 页，第 20 页为共用参考页。

个人计时 00:00-15:00：正文目标 14:30，缓冲 00:30。 全场排练基准为 15:00-30:00；A 可提前交接，B 接棒时将个人计时归零，不必等满第 15 分钟。

- 中英文是两个可选版本。正式演讲选一种语言；两人使用一致语言，本稿不要求重复讲两遍。

- 视频合计 20 秒、互动、45 秒排序演示或 20 秒候选切换（如适用）、停顿与交接均已计入。视频只播一次，播放时不重复朗读录制旁白。

- 方括号内为操作提示，不朗读。每个互动问题只收一个简短回答；演示时照稿讲解，不额外扩展预设。

- 英文按每分钟 110 个词估算；中文按每分钟 200 个等效单位估算，外文与数字加算时间。时间为排练规划，请按每页累计节点试讲。

- 若到 14:30 仍未收束，A 直接说交接语，B 直接说最后三个结论；略过追加互动，不重播视频，并在个人 15:00 前结束。第 20 页与问答均在两人演讲之后使用。

页码与标题	个人时间	全场基准	视频
10. 先读实验协议，再读结果	00:00-01:25	15:00-16:25	0s
11. 正确标签与合理错误是两种指标	01:25-02:45	16:25-17:45	0s
12. 准确率接近，错误结构不同	02:45-04:10	17:45-19:10	0s
13. 候选标签越多，测试越困难	04:10-06:30	19:10-21:30	20s
14. 语义改善也有边界	06:30-07:35	21:30-22:35	0s
15. 候选集合可以改变方法排名	07:35-08:45	22:35-23:45	0s
16. 证据还没有证明什么	08:45-10:40	23:45-25:40	0s
17. 与 ProtoNet 建立联系，但不混淆任务	10:40-11:50	25:40-26:50	0s
18. 可以扩展的标签词表	11:50-12:50	26:50-27:50	0s
19. 带走三个结论	12:50-14:30	27:50-29:30	0s

个人 14:30-15:00 仅作缓冲，已包含在 15 分钟限时内。

10. 先读实验协议，再读结果

流程时间：个人 00:00-01:25；全场基准 15:00-16:25。 讲者 B。视频 0 秒，互动或演示 5 秒，停顿与换页 4 秒，均已计入。

谢谢。刚才我们了解了模型怎样工作，接下来我会重点看实验究竟支持哪些结论。看主要数字前，先确认它们怎么得来。

在主要的已见类别评估中，作者划分了原始 ImageNet 验证集：五千张用于模型选择，四万五千张用于报告结果。这不是竞赛隐藏测试集。补充材料还说明，测试使用单个中心裁剪，softmax 基线采用相同评估流程。

零样本实验直接复用五百维模型，没有进一步调参。但 Table 4 改用了不同年份的数据集和类别划分，不能把它的百分比与 Table 2 当作同一个任务直接比较。

互动问题: 为什么 Table 2 和 Table 4 回答的是不同的实验问题？

协议清楚之后，下一个问题是：怎样才算预测成功？

依据： Supplement §A.1, p.1; main paper pp.6-8

11. 正确标签与合理错误是两种指标

流程时间：个人 01:25-02:45；全场基准 16:25-17:45。 讲者 B。视频 0 秒，互动或演示 8 秒，停顿与换页 4 秒，均已计入。

假设真实标签是一种鸟，模型却预测了相关的另一种鸟。按准确标签评估，这仍然是错的；层级指标则可以给语义相近的答案一定认可。

可接受集合会沿着分类层级，在真实标签周围逐步扩展，直到至少包含 k 个标签。由于每次加入整个邻域，集合大小可能超过 k。

所以，层级精度与准确标签正确率回答的是不同问题，而且依赖分类层级。当 k 等于一时，只有准确标签可接受；换成相同单位后，两种指标一致。

互动问题: 层级分数更高，是否一定意味着准确物种预测更多？

带着这个区别，我们来看已见类别的结果。

依据： Main §4, pp.4-5; Supplement §A.3, pp.2-3

12. 准确率接近，错误结构不同

流程时间：个人 02:45-04:10；全场基准 17:45-19:10。 讲者 B。视频 0 秒，互动或演示 8 秒，停顿与换页 4 秒，均已计入。

熟悉的一千个类别上，结果很接近。Top-1 中，softmax 是百分之五十五点六，一千维 DeViSE 是百分之五十四点九。Top-5 几乎打平：百分之七十八点五，对百分之七十八点四。

部分层级分数有所提高，说明错误的结构可能不同，而不是准确标签正确率有明确的全面优势。

随机嵌入基线帮助我们检查：文本带来的标签几何结构有没有用。它保留大体架构，却去掉标签间有意义的组织。这是有用证据，但没有控制所有可能的训练差异。

互动问题: 哪个基线检验有意义的标签几何结构是否有用？

已见类别先看到这里。更有特色的测试是：没有某类的训练图像，模型还能叫出它的名字吗？

依据： Table 1, p.5

13. 候选标签越多，测试越困难

流程时间：个人 04:10-06:30；全场基准 19:10-21:30。 讲者 B。视频 20 秒，互动或演示 10 秒，停顿与换页 4 秒，均已计入。



Figure 2: For each image, the top 5 zero-shot predictions of DeViSE+1K from the 2011 21K label set and the softmax baseline model, both trained on ILSVRC 2012 1K. Predictions ordered by decreasing score, with correct predictions in bold. Ground truth: (a) *telephoto lens, zoom lens*; (b) *English horn, cor anglais*; (c) *babbler, cackler*; (d) *pineapple, pineapple plant, Ananas comosus*; (e) *salad bar*; (f) *spacecraft, ballistic capsule, space vehicle*.

原论文 Figure 2 - Frome et al., NIPS 2013

查看原论文页码 6

播放前 · 演讲者说：

Figure 2 是作者选取的零样本案例。请留意一次准确预测、一次合理但未命中的预测，以及一个基线更好的例子。

播放提示 · Figure 2 · 中文 · 20 秒：

播放一次 Figure 2 中文视频，结束后再继续讲解。

播放视频（20 秒）

字幕

视频旁白 · 已录制，请勿重复朗读：

模型能识别未见类别吗？ 镜头的正确标签，排第四。 沙拉吧，两个模型都没命中。 而飞船，softmax 的预测更相关。 案例展示优点与局限，不代表总体准确率。

播放后 · 演讲者说：

镜头的准确标签排在第四。沙拉吧的准确标签两者都没命中；航天器的预测，作者认为 softmax 更接近正确答案。这说明迁移有用，也有局限。

两者都在 ImageNet 一千类上训练。DeViSE 搜索更大的标签词表，softmax 只能输出训练标签。D图里，合理的菠萝水果预测，不等于特定的菠萝植株同义词集。先确认什么算准确匹配。

互动问题: 哪个例子挑战了“DeViSE 总能赢”的说法？合理标签仍可能是准确标签未命中吗？

衔接 Table 2 与下一章 · 演讲者说：

精选案例不能给出总体准确率，要看 Table 2。2-hop 的 hit@5，只考虑未见候选时是百分之十八点一；加入一千个已见候选，降到百分之七点九。模型相同，候选集合不同。全部两万零八百四十一个未见标签下，hit@1 是百分之零点八，hit@5 是百分之二点五。接下来，我们再看剩下的错误有多合理。

依据： Original Figure 2 and Table 2, p.6; §4.2 reading, p.7

14. 语义改善也有边界

流程时间：个人 06:30-07:35；全场基准 21:30-22:35。 讲者 B。视频 0 秒，互动或演示 5 秒，停顿与换页 4 秒，均已计入。

层级结果同样取决于设置。在 2-hop、k 等于二的任务中，softmax 分数更高；完整标签集、k 等于二十时，DeViSE+1K 更好。

这支持有条件的语义泛化结论，而不是 DeViSE 处处获胜。WordNet 在这里有明确角色：用于评估语义接近程度，不用于训练这些标签嵌入。

互动问题: WordNet 在这里用于训练嵌入，还是评估预测？

Table 4 又提供了一个例子，说明比较设置为什么重要。

依据： Table 3, p.7; Supplement §A.3

15. 候选集合可以改变方法排名

流程时间：个人 07:35-08:45；全场基准 22:35-23:45。 讲者 B。视频 0 秒，互动或演示 5 秒，停顿与换页 4 秒，均已计入。

Table 4 采用独立划分：八百个已见类别、两百个未见类别。只让两百个未见标签作为候选时，DeViSE 落后于 Mensink 的方法；一千个标签都参加竞争时，排名反过来了。

一种设置要求答案必须是未见类；另一种让已见与未见标签竞争。还要保留论文的说明：Rohrbach 使用了不同的未见类别集合。

互动问题: 为什么允许已见标签竞争，会让两种方法的排名反过来？

综合这些表格，结论是一致的：候选集合是任务的一部分，不是报告时无关紧要的小细节。接下来讨论模型更广泛的局限。

依据： Table 4, p.7; split description pp.7-8

16. 证据还没有证明什么

流程时间：个人 08:45-10:40；全场基准 23:45-25:40。 讲者 B。视频 0 秒，互动或演示 12 秒，停顿与换页 4 秒，均已计入。

现在可以回答开场的问题了，但要带上条件：只要有合适的语义表示，DeViSE 就能给没有该类有标注训练图像的标签排序。

它仍然需要候选词表，并不是自由生成图像描述。词义也可能有歧义：crane 可以指鸟，也可以指起重机，但语言模型只为这个词提供一个向量。

合理的结果和可靠的识别之间，还有距离。最大标签集上的准确率偏低，已见类别也可能把预测从未见类别吸引过去。

一个有用的后续实验，是固定测试图像和候选数量，只改变已见候选与真实未见标签的语义相似程度。这样有助于区分语义竞争与单纯候选增多的影响。这是新的实验设想，不是本文已经建立的结果。

互动问题: 要区分语义竞争与候选集合大小的影响，你会固定哪些条件？

这些边界也帮助我们把 DeViSE 与熟悉的另一种方法联系起来：ProtoNet。

依据： Main §4.2-5, pp.6-8; Supplement §A.2

17. 与 ProtoNet 建立联系，但不混淆任务

流程时间：个人 10:40-11:50；全场基准 25:40-26:50。 讲者 B。视频 0 秒，互动或演示 5 秒，停顿与换页 4 秒，均已计入。

DeViSE 和 ProtoNet 都比较图像表示与类别表示。关键区别在于，类别表示从哪里来。

ProtoNet 对新类的少量有标注支持图像求嵌入均值，得到原型；DeViSE 则从语言模型取得类别表示。所以，在没有这些支持图像时，它使用的是另一种信息资源。

这是一种概念上的联系。数据集和监督条件不同，论文里的准确率不能直接比较。

互动问题: 没有支持图像时，两种方法分别从哪里取得类别表示？

两者共享的思路，是灵活地表示一个类别。那么，这种灵活性在实际应用中能带来什么？

依据： DeViSE §3.3; Snell et al. (2017), §2

18. 可以扩展的标签词表

流程时间：个人 11:50-12:50；全场基准 26:50-27:50。 讲者 B。视频 0 秒，互动或演示 5 秒，停顿与换页 4 秒，均已计入。

共享嵌入模型可以支持不同的标签词表。一个应用可能用汽车、行人等粗粒度标签；另一个可能需要更具体的车型名称。只要文本嵌入合适，同一视觉映射就能为任一词表排序。

这种灵活性很有吸引力，但加一个词，并不保证能识别它。实际系统还需要领域评估、明确的候选集合，以及处理歧义和真正未知输入的方法。

互动问题: 加入一个新词，就能保证可靠识别吗？

这些是可能性，不是已展示的部署。最后，用三个结论收束。

依据： §5, p.8: proposed applications, not deployment evidence

19. 带走三个结论

流程时间：个人 12:50-14:30；全场基准 27:50-29:30。 讲者 B。视频 0 秒，互动或演示 5 秒，停顿与换页 4 秒，均已计入。

第一，语言为视觉识别提供了图像训练标签之外的类别结构。

第二，DeViSE 用排序目标连接两种表示：正确标签的分数应高于竞争标签。

第三，理解结果必须看评估设置。在 2-hop 例子里，只改变候选集合，hit@5 就从百分之十八点一变成百分之七点九。语义桥梁有用，但成功有条件。

所以，答案是可以：有意义的标签表示，能帮助识别部分视觉上未见的类别；成功仍取决于候选词表。

互动问题: 声称 DeViSE 能识别未见类别时，必须补上什么条件？

谢谢大家，接下来我们一起回答问题。

依据： Frome et al. (2013), p.8

20. 来源、证据与可复算说明

参考页，不计入限时演讲。 两人共用，不逐项朗读。

[参考页 · 不计入限时演讲。不逐项朗读；留待单独的问答环节使用。]

下载区提供原文、官方补充材料、阅读指南和视频素材。报告结果注明论文来源；互动计算是教学示例。这里没有复现原始 ImageNet 训练。

参考提问: 哪些证据来自论文，哪些来自教学示例？

依据： Frome et al. (2013), p.1

问答准备 - 备用，不计入个人 15 分钟

两人演讲结束后再进入问答；以下为建议主答分工，另一位可以补充。

8. 18.1% 究竟指什么？

DeViSE-0 在 1,589 个 2-hop 未见候选上的 flat hit@5；不是 top-1，也不是全 21K 结果。

依据： Table 2, p.6

9. 整个研究都没有使用 WordNet 吗？

不是。文本嵌入训练不以人工层级为目标，但评估使用 ImageNet/WordNet 层级。

依据： §2; Supplement §A.3

10. DeViSE 每个指标都超过 softmax 吗？

不是。已见类 top-1 和一些层级设置中 softmax 更好。必须同时说明指标和候选集合。

依据： Tables 1 and 3

12. 它与 ProtoNet 有何不同？

DeViSE 从文本获得类别向量；ProtoNet 通常从标注支持图像求均值。资源假设和目标不同。

依据： DeViSE §3; Snell et al. §2

13. 多义标签怎么办？

同一个词向量可能对应多个 synset。补充材料将词展开为 synset、去重并截取排名，但这并未在嵌入中真正区分词义。

依据： Supplement §A.2

14. 能直接比较 Table 2 和 Table 4 吗？

不能。Table 4 是 ImageNet 2010 的 800/200 类划分；Table 2 使用 2012 训练模型和 2011 未见类。

依据： Supplement §A.1

15. 你会如何改进？

可检验词义区分嵌入、候选集合校准和受控域偏移。这是建议研究，不是已测结果。

依据： Presenter proposals