DeViSE - 完整中文演讲稿

Li Hu · COMP6710 · Frome 等，NIPS 2013

讲解与时间控制

目标 28:00，另留 2:00 缓冲，总计不超过 30:00。问答环节在限时演讲之后。

- 与最新版英文稿逐章对齐：论点、例子、数字、限定条件、互动问题和转场保持一致。

- 以每分钟约 200 字估算，并为外文术语和数字加算读音时间。正文和互动问题包含 3,829 个汉字；舞台提示和录制旁白不作为额外演讲文字计时。

- 总览、Figure 1 和 Figure 2 各播放一次，每段 20 秒，合计 60 秒。视频播放时不重复朗读旁白。

- 演示及观众等待预留 176 秒，含 45 秒排序演示、20 秒候选切换；停顿和换页另计 76 秒。

- 这是时间规划估算，不是现场实测。按下面的累计节点排练，观众回答保持简短，不无限等待。舞台提示、表头和来源不逐项朗读。

- 若进度落后，跳过可选语义滑尺、额外演示预设和追加回答；不重播视频。若到 28:00 还未收束，直接进入三个结论，并在 30:00 前结束。

章节	累计时间	视频	互动或演示
1. 模型能认出从未见过的类别吗？	00:00-01:05	0 秒	5 秒
2. 没有训练图片，不等于没有信息	01:05-02:20	0 秒	5 秒
3. 连接图像与词语的研究缺口	02:20-03:35	0 秒	5 秒
4. 两个预训练模型，一个语义接口	03:35-05:15	20 秒	5 秒
5. 语义结构从哪里来	05:15-07:30	20 秒	8 秒
6. 不仅靠近正确标签，还要排在错误标签之前	07:30-09:10	0 秒	10 秒
7. 训练时哪些参数会更新？	09:10-10:25	0 秒	5 秒
8. 逐步检查一次排序更新	10:25-12:25	0 秒	45 秒
9. 候选词表会改变答案	12:25-13:50	0 秒	20 秒
10. 先读实验协议，再读结果	13:50-15:05	0 秒	5 秒
11. 正确标签与合理错误是两种指标	15:05-16:25	0 秒	8 秒
12. 准确率接近，错误结构不同	16:25-17:50	0 秒	8 秒
13. 候选标签越多，测试越困难	17:50-20:10	20 秒	10 秒
14. 语义改善也有边界	20:10-21:15	0 秒	5 秒
15. 候选集合可以改变方法排名	21:15-22:25	0 秒	5 秒
16. 证据还没有证明什么	22:25-24:20	0 秒	12 秒
17. 与 ProtoNet 建立联系，但不混淆任务	24:20-25:30	0 秒	5 秒
18. 可以扩展的标签词表	25:30-26:30	0 秒	5 秒
19. 带走三个结论	26:30-28:00	0 秒	5 秒

28:00-30:00 仅作缓冲。 参考页和问答不计入此流程。

1. 模型能认出从未见过的类别吗？

流程时间：00:00-01:05。 互动或演示预留 5 秒；停顿与换页预留 4 秒。

大家好，今天我们讨论 DeViSE：怎样把视觉识别和语言中学到的含义连接起来。

先想一个问题。假设一个分类器学会了认狗，但输出层里根本没有“鲨鱼”这个标签，它还能把一张图片叫作鲨鱼吗？识别一张新照片，和识别一个新类别，是两回事。

互动问题: 固定的 softmax 输出层，能预测一个不在输出列表里的标签吗？

DeViSE 尝试借助文本跨过这道鸿沟。要理解它怎么做，我们先得说清楚：“未见”究竟指什么。

依据：Frome et al. (2013), p.1

2. 没有训练图片，不等于没有信息

流程时间：01:05-02:20。 互动或演示预留 5 秒；停顿与换页预留 4 秒。

在这篇论文里，未见类别是指视觉模型没有该类的有标注训练图像。这不等于系统对它一无所知；类别名称仍然可能出现在语言模型使用的文本里。

例如，视觉模型见过某些鲨鱼种类，而文本为另一种鲨鱼提供了词向量。目标就是把有用的结构迁移过去。

这里还要分清两个集合：接受测试的图像，和允许作为答案的标签。把已见标签加入候选答案，并不会改变测试图像。

互动问题: 对于未见类别，系统还可以获得什么信息？

明确这个设置之后，我们再看，早期方法还缺少哪一环。

依据：Frome et al. (2013), p.2

3. 连接图像与词语的研究缺口

流程时间：02:20-03:35。 互动或演示预留 5 秒；停顿与换页预留 4 秒。

当时，主要的构件已经存在：卷积网络能学习有用的视觉特征，语言模型也能把含义相关的词放在相近的位置。难点是把两者连接起来，并让这种连接适用于大得多的标签词表。

这就是论文的贡献：把预训练视觉特征、从文本得到的标签表示和排序目标结合起来，做到 ImageNet 的规模。作者用一千个视觉类别训练，再研究向大约两万个额外标签迁移。

多项设计同时发生了变化，所以应评价整套方法，不能把所有改善都归因于规模。

互动问题: 语义标签表示带来了什么，是单纯扩大 softmax 不能提供的？

接下来，我们沿着信息流看一遍模型。

依据：Frome et al. (2013), p.2

4. 两个预训练模型，一个语义接口

流程时间：03:35-05:15。 已含 20 秒视频。互动或演示预留 5 秒；停顿与换页预留 4 秒。

播放前 · 演讲者说：

先用二十秒抓住整体思路。请留意图像怎样从视觉特征进入一个与标签含义共享的空间。然后，我们再回到作者的原图，检查具体细节。

播放提示 · DeViSE 总览 · 中文 · 20 秒：

播放一次中文总览视频。等录制旁白完整结束，再继续讲解。

播放总览中文视频（20 秒）

下载中文字幕

视频旁白 · 已录制，请勿重复朗读：

没有斑马训练图，也能认出斑马吗？先用文本学词向量，用图片训练视觉网络。再把图像投影到语义空间，让正确标签得分更高。预测时比较标签得分，也能选择未见类别。前提是，已有它的词向量。

播放后 · 演讲者说：

关键的一步，是把固定输出类别的分类，改成图像向量与候选标签向量之间的比较。文本提供标签表示，训练图像教会视觉映射。只要有对应嵌入，新标签就能加入比较。这为零样本识别提供了一条路径，但不保证预测一定正确。

互动问题: 哪个部分把视觉特征连接到标签空间？

衔接 Figure 1 · 演讲者说：

刚才是整体思路。现在看原始 Figure 1，弄清两种表示从哪里来，以及模型到底学习了什么。

依据：Frome et al. (2013), p.3

5. 语义结构从哪里来

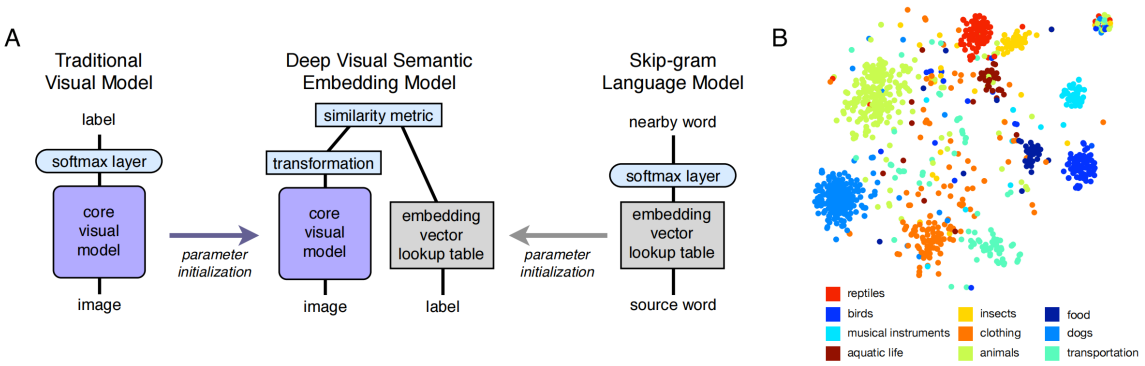


Figure 1: (a) Left: a visual object categorization network with a softmax output layer; Right: a skip-gram language model; Center: our joint model, which is initialized with parameters pre-trained at the lower layers of the other two models. (b) t-SNE visualization [19] of a subset of the ILSVRC 2012 1K label embeddings learned using skip-gram.

原论文 Figure 1 - Frome et al., NIPS 2013

查看原论文页码 3

流程时间：05:15-07:30。 已含 20 秒视频。互动或演示预留 8 秒；停顿与换页预留 4 秒。

播放前 · 演讲者说：

Figure 1 有两个面板。接下来这段短片里，请跟着两个预训练模型进入联合系统，再看看 B 图中不同颜色的语义邻域。

播放提示 · Figure 1 · 中文 · 20 秒：

播放一次 Figure 1 中文视频，结束后再继续讲解。

播放 Figure 1 中文视频（20 秒）

下载中文字幕

视频旁白 · 已录制，请勿重复朗读：

DeViSE 如何连接视觉与语言？ 它结合预训练视觉网络，与固定的词向量。 学习一个投影，让图像对齐标签向量。 B 图展示标签之间的语义邻域，不是图像预测结果。

播放后 · 演讲者说：

A 图展示架构。指向中间的箭头表示参数初始化。视觉 softmax 被移除，学习到的投影把视觉特征映射到标签空间。视觉特征有四千零九十六维；论文使用五百维或一千维的标签嵌入。

B 图展示的是另一件事：用 t-SNE 可视化从文本学到的标签嵌入。在图像训练对齐两种模态之前，相关标签就已经形成邻域。这些点是标签，不是测试图像的预测；二维距离也不是分类分数。

词向量归一化后保持固定。先学习投影，再微调视觉网络。继续之前，我们先确认各部分的角色。

互动问题: B 图中的点是标签还是测试图像？图上的距离是预测分数吗？

衔接排序损失 · 演讲者说：

现在有了参照空间。怎样让图像更偏向正确标签，而不是竞争标签？这就是排序损失要解决的问题。

依据：Original Figure 1 and §3.1-3.3, p.3

6. 不仅靠近正确标签，还要排在错误标签之前

流程时间：07:30-09:10。 互动或演示预留 10 秒；停顿与换页预留 4 秒。

这个目标关心的是先后顺序。我们希望正确标签的分数，比竞争标签至少高出一个小的间隔。

把铰链损失这一项读出来，就是：要求的间隔，减去正确标签分数，再加上竞争标签分数。如果正确标签已经充分领先，损失就是零；否则，这一对标签会产生学习信号。

做个简单计算：间隔是零点一，正确分数是零点六，竞争分数是零点五五，损失就是零点零五。正确标签虽然领先，但领先得还不够。

公式一写成求和；实际算法会抽取竞争标签，在第一个违反间隔的标签处停止，而不是每次更新都检查所有标签。

互动问题: 正确标签已经得分更高，为什么损失仍然大于零？

目标已经清楚了。接下来看看，它会改变模型的哪些部分。

依据：Frome et al. (2013), p.4

7. 训练时哪些参数会更新？

流程时间：09:10-10:25。 互动或演示预留 5 秒；停顿与换页预留 4 秒。

预训练给模型一个起点，并不意味着所有部分都保持冻结。

作者先训练投影矩阵 M，再微调视觉网络，同时固定语言嵌入。论文采用异步随机梯度下降，并使用 Adagrad 学习率。

我们的教学示例刻意缩小了问题：固定二维视觉特征，只用普通梯度下降更新 M。这样能单独检查一个排序约束的影响，而不是假装复现完整的 ImageNet 训练。

互动问题: 视觉网络在整个训练过程中都保持冻结吗？

明确这个简化之后，我们走一遍更新，看看分数差是否按预期改变。

依据：Frome et al. (2013), p.4

8. 逐步检查一次排序更新

流程时间：10:25-12:25。 互动或演示预留 45 秒；停顿与换页预留 4 秒。

现在看这个可计算的小示例。图像特征和标签向量都固定，只有投影发生变化。开始之前，先预测一下：正确分数与竞争分数之间的差距会怎样变化？

[演示提示 · 共 45 秒，含观众回答。间隔和学习率都设为 0.1；前进一步，查看分数差，再倒退，最后试一次零学习率。跳过额外预设和可选语义滑尺。]

这次有效更新后，分数差增大，损失下降。倒退可以恢复相同状态。把学习率设为零，模型就不变，说明结果确实由更新驱动。

这只是教学问题里的一个约束，不能证明真实训练中的每个样本每一步都会改善。这里的相似度分数也不是概率。

互动问题: 一次有效更新后，正确标签与竞争标签的分数差应该怎样变化？

我们看过学习怎样改变分数了。那么，如果分数不变，只改变可选答案，会发生什么？

依据：Teaching derivation from Eq.1, p.4; computed toy, not a reported experiment

9. 候选词表会改变答案

流程时间：12:25-13:50。 互动或演示预留 20 秒；停顿与换页预留 4 秒。

保持图像向量不变，只改变候选列表。只有未见标签时，未见的鲨鱼标签获胜；让一个相近的已见鲨鱼标签参加竞争，第一名就可能换成这个熟悉标签。

[演示提示 · 共 20 秒，含观众回答。只切换一次“加入已见候选”，保持查询角度不变。]

这里没有重新训练。DeViSE-0 和 DeViSE+1K 表示同一个训练模型使用不同候选集合；两种设置都测试未见类别的图像。

当标签向量为单位长度、查询向量固定且非零时，点积与余弦的排序一致，但数值和固定间隔损失不一定相同。

互动问题: 加入已见候选时，模型权重改变了吗？

答案列表会影响结果，所以接下来必须看清评估协议。

依据：Frome et al. (2013), p.6

10. 先读实验协议，再读结果

流程时间：13:50-15:05。 互动或演示预留 5 秒；停顿与换页预留 4 秒。

看主要数字前，先确认它们怎么得来。

在主要的已见类别评估中，作者划分了原始 ImageNet 验证集：五千张用于模型选择，四万五千张用于报告结果。这不是竞赛隐藏测试集。补充材料还说明，测试使用单个中心裁剪，softmax 基线采用相同评估流程。

零样本实验直接复用五百维模型，没有进一步调参。但 Table 4 改用了不同年份的数据集和类别划分，不能把它的百分比与 Table 2 当作同一个任务直接比较。

互动问题: 为什么 Table 2 和 Table 4 回答的是不同的实验问题？

协议清楚之后，下一个问题是：怎样才算预测成功？

依据：Supplement §A.1, p.1; main paper pp.6-8

11. 正确标签与合理错误是两种指标

流程时间：15:05-16:25。 互动或演示预留 8 秒；停顿与换页预留 4 秒。

假设真实标签是一种鸟，模型却预测了相关的另一种鸟。按准确标签评估，这仍然是错的；层级指标则可以给语义相近的答案一定认可。

可接受集合会沿着分类层级，在真实标签周围逐步扩展，直到至少包含 k 个标签。由于每次加入整个邻域，集合大小可能超过 k。

所以，层级精度与准确标签正确率回答的是不同问题，而且依赖分类层级。当 k 等于一时，只有准确标签可接受；换成相同单位后，两种指标一致。

互动问题: 层级分数更高，是否一定意味着准确物种预测更多？

带着这个区别，我们来看已见类别的结果。

依据：Main §4, pp.4-5; Supplement §A.3, pp.2-3

12. 准确率接近，错误结构不同

流程时间：16:25-17:50。 互动或演示预留 8 秒；停顿与换页预留 4 秒。

熟悉的一千个类别上，结果很接近。Top-1 中，softmax 是百分之五十五点六，一千维 DeViSE 是百分之五十四点九。Top-5 几乎打平：百分之七十八点五，对百分之七十八点四。

部分层级分数有所提高，说明错误的结构可能不同，而不是准确标签正确率有明确的全面优势。

随机嵌入基线帮助我们检查：文本带来的标签几何结构有没有用。它保留大体架构，却去掉标签间有意义的组织。这是有用证据，但没有控制所有可能的训练差异。

互动问题: 哪个基线检验有意义的标签几何结构是否有用？

已见类别先看到这里。更有特色的测试是：没有某类的训练图像，模型还能叫出它的名字吗？

依据：Table 1, p.5

13. 候选标签越多，测试越困难

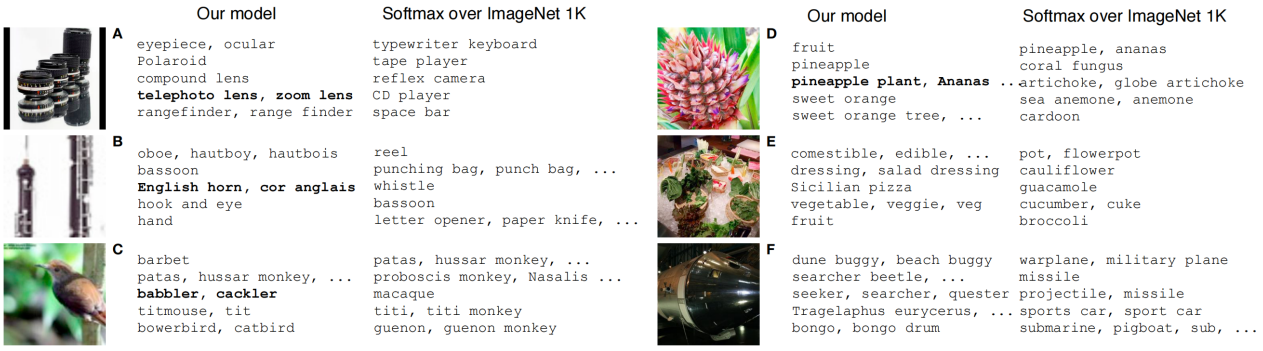


Figure 2: For each image, the top 5 zero-shot predictions of DeViSE+1K from the 2011 21K label set and the softmax baseline model, both trained on ILSVRC 2012 1K. Predictions ordered by decreasing score, with correct predictions in bold. Ground truth: (a) *telephoto lens, zoom lens*; (b) *English horn, cor anglais*; (c) *babbler, cackler*; (d) *pineapple, pineapple plant, Ananas comosus*; (e) *salad bar*; (f) *spacecraft, ballistic capsule, space vehicle*.

原论文 Figure 2 - Frome et al., NIPS 2013

查看原论文页码 6

流程时间：17:50-20:10。 已含 20 秒视频。互动或演示预留 10 秒；停顿与换页预留 4 秒。

播放前 · 演讲者说：

Figure 2 是作者选取的零样本案例。请留意一次准确预测、一次合理但未命中的预测，以及一个基线更好的例子。

播放提示 · Figure 2 · 中文 · 20 秒：

播放一次 Figure 2 中文视频，结束后再继续讲解。

播放 Figure 2 中文视频（20 秒）

下载中文字幕

视频旁白 · 已录制，请勿重复朗读：

模型能识别未见类别吗？ 镜头的正确标签，排第四。 沙拉吧，两个模型都没命中。 而飞船，softmax 的预测更相关。 案例展示优点与局限，不代表总体准确率。

播放后 · 演讲者说：

镜头的准确标签排在第四。沙拉吧的准确标签两者都没命中；航天器的预测，作者认为 softmax 更接近正确答案。这说明迁移有用，也有局限。

两者都在 ImageNet 一千类上训练。DeViSE 搜索更大的标签词表，softmax 只能输出训练标签。D 图里，合理的菠萝水果预测，不等于特定的菠萝植株同义词集。先确认什么算准确匹配。

互动问题: 哪个例子挑战了“DeViSE 总能赢”的说法？合理标签仍可能是准确标签未命中吗？

衔接 Table 2 与下一章 · 演讲者说：

精选案例不能给出总体准确率，要看 Table 2。2-hop 的 hit@5，只考虑未见候选时是百分之十八点一；加入一千个已见候选，降到百分之七点九。模型相同，候选集合不同。全部两万零八百四十一个未见标签下，hit@1 是百分之零点八，hit@5 是百分之二点五。接下来，我们再看剩下的错误有多合理。

依据：Original Figure 2 and Table 2, p.6; §4.2 reading, p.7

14. 语义改善也有边界

流程时间：20:10-21:15。 互动或演示预留 5 秒；停顿与换页预留 4 秒。

层级结果同样取决于设置。在 2-hop、k 等于二的任务中，softmax 分数更高；完整标签集、k 等于二十时，DeViSE+1K 更好。

这支持有条件的语义泛化结论，而不是 DeViSE 处处获胜。WordNet 在这里有明确角色：用于评估语义接近程度，不用于训练这些标签嵌入。

互动问题: WordNet 在这里用于训练嵌入，还是评估预测？

Table 4 又提供了一个例子，说明比较设置为什么重要。

依据：Table 3, p.7; Supplement §A.3

15. 候选集合可以改变方法排名

流程时间：21:15-22:25。 互动或演示预留 5 秒；停顿与换页预留 4 秒。

Table 4 采用独立划分：八百个已见类别、两百个未见类别。只让两百个未见标签作为候选时，DeViSE 落后于 Mensink 的方法；一千个标签都参加竞争时，排名反过来了。

一种设置要求答案必须是未见类；另一种让已见与未见标签竞争。还要保留论文的说明：Rohrbach 使用了不同的未见类别集合。

互动问题: 为什么允许已见标签竞争，会让两种方法的排名反过来？

综合这些表格，结论是一致的：候选集合是任务的一部分，不是报告时无关紧要的小细节。接下来讨论模型更广泛的局限。

依据：Table 4, p.7; split description pp.7-8

16. 证据还没有证明什么

流程时间：22:25-24:20。 互动或演示预留 12 秒；停顿与换页预留 4 秒。

现在可以回答开场的问题了，但要带上条件：只要有合适的语义表示，DeViSE 就能给没有该类有标注训练图像的标签排序。

它仍然需要候选词表，并不是自由生成图像描述。词义也可能有歧义：crane 可以指鸟，也可以指起重机，但语言模型只为这个词提供一个向量。

合理的结果和可靠的识别之间，还有距离。最大标签集上的准确率偏低，已见类别也可能把预测从未见类别吸引过去。

一个有用的后续实验，是固定测试图像和候选数量，只改变已见候选与真实未见标签的语义相似程度。这样有助于区分语义竞争与单纯候选增多的影响。这是新的实验设想，不是本文已经建立的结果。

互动问题: 要区分语义竞争与候选集合大小的影响，你会固定哪些条件？

这些边界也帮助我们把 DeViSE 与熟悉的另一种方法联系起来：ProtoNet。

依据：Main §4.2-5, pp.6-8; Supplement §A.2

17. 与 ProtoNet 建立联系，但不混淆任务

流程时间：24:20-25:30。 互动或演示预留 5 秒；停顿与换页预留 4 秒。

DeViSE 和 ProtoNet 都比较图像表示与类别表示。关键区别在于，类别表示从哪里来。

ProtoNet 对新类的少量有标注支持图像求嵌入均值，得到原型；DeViSE 则从语言模型取得类别表示。所以，在没有这些支持图像时，它使用的是另一种信息资源。

这是一种概念上的联系。数据集和监督条件不同，论文里的准确率不能直接比较。

互动问题: 没有支持图像时，两种方法分别从哪里取得类别表示？

两者共享的思路，是灵活地表示一个类别。那么，这种灵活性在实际应用中能带来什么？

依据：DeViSE §3.3; Snell et al. (2017), §2

18. 可以扩展的标签词表

流程时间：25:30-26:30。 互动或演示预留 5 秒；停顿与换页预留 4 秒。

共享嵌入模型可以支持不同的标签词表。一个应用可能用汽车、行人等粗粒度标签；另一个可能需要更具体的车型名称。只要文本嵌入合适，同一视觉映射就能为任一词表排序。

这种灵活性很有吸引力，但加一个词，并不保证能识别它。实际系统还需要领域评估、明确的候选集合，以及处理歧义和真正未知输入的方法。

互动问题: 加入一个新词，就能保证可靠识别吗？

这些是可能性，不是已展示的部署。最后，用三个结论收束。

依据：§5, p.8: proposed applications, not deployment evidence

19. 带走三个结论

流程时间：26:30-28:00。 互动或演示预留 5 秒；停顿与换页预留 4 秒。

第一，语言为视觉识别提供了图像训练标签之外的类别结构。

第二，DeViSE 用排序目标连接两种表示：正确标签的分数应高于竞争标签。

第三，理解结果必须看评估设置。在 2-hop 例子里，只改变候选集合，hit@5 就从百分之十八点一变成百分之七点九。语义桥梁有用，但成功有条件。

所以，答案是可以：有意义的标签表示，能帮助识别部分视觉上未见的类别；成功仍取决于候选词表。

互动问题: 声称 DeViSE 能识别未见类别时，必须补上什么条件？

谢谢大家，欢迎提问。

依据：Frome et al. (2013), p.8

20. 来源、证据与可复算说明

参考页，不计入限时演讲。

[参考页 · 不计入限时演讲。不逐项朗读；留待单独的问答环节使用。]

下载区提供原文、官方补充材料、阅读指南和视频素材。报告结果注明论文来源；互动计算是教学示例。这里没有复现原始 ImageNet 训练。

互动问题: 哪些证据来自论文，哪些来自教学示例？

依据：Frome et al. (2013), p.1

问答准备 - 备用，不计入限时演讲

1. 文本出现过类名，为什么仍是零样本？

零样本相对于这些类别的视觉训练样本定义；语义辅助信息是明确允许的。

依据：§4.2, p.6

2. 原文联合训练会更新词向量吗？

原文固定词向量。脚注讨论同时训练语言模型的可能性，不是已报告流程。

依据：§3.3, p.4, footnote 5

3. 视觉骨干一直冻结吗？

不是。先训练 M，再微调视觉网络。

依据：§3.3, p.4

4. 为什么用排序损失而不是 L2？

预测依赖排序。Hinge 明确惩罚过于接近或超过正确标签的错误标签。论文报告 L2 较差，但不构成普遍保证。

依据：§3.3, p.4

5. 点积和余弦完全相同吗？

单位标签向量与固定非零查询下，排序相同；数值相差查询模长，固定间隔损失不一定相同。

依据：§3.3 + algebraic deduction

6. 相似度分数是概率吗？

不是。教学例子和论文目标使用点积分数，没有建立概率校准。

依据：Eq.1, p.4

7. DeViSE-0 和 +1K 是不同训练模型吗？

不是。是同一个训练模型，候选标签集合不同。

依据：Table 2 caption, p.6

8. 18.1% 究竟指什么？

DeViSE-0 在 1,589 个 2-hop 未见候选上的 flat hit@5；不是 top-1，也不是全 21K 结果。

依据：Table 2, p.6

9. 整个研究都没有使用 WordNet 吗？

不是。文本嵌入训练不以人工层级为目标，但评估使用 ImageNet/WordNet 层级。

依据：§2; Supplement §A.3

10. DeViSE 每个指标都超过 softmax 吗？

不是。已见类 top-1 和一些层级设置中 softmax 更好。必须同时说明指标和候选集合。

依据：Tables 1 and 3

11. 随机嵌入基线控制什么？

它移除学习到的标签语义结构、保留嵌入模型形式，支持语义有效，但不完美隔离全部混杂因素。

依据：§4 and Table 1

12. 它与 ProtoNet 有何不同？

DeViSE 从文本获得类别向量；ProtoNet 通常从标注支持图像求均值。资源假设和目标不同。

依据：DeViSE §3; Snell et al. §2

13. 多义标签怎么办？

同一个词向量可能对应多个 synset。补充材料将词展开为 synset、去重并截取排名，但这并未在嵌入中真正区分词义。

依据：Supplement §A.2

14. 能直接比较 Table 2 和 Table 4 吗？

不能。Table 4 是 ImageNet 2010 的 800/200 类划分；Table 2 使用 2012 训练模型和 2011 未见类。

依据：Supplement §A.1

15. 你会如何改进？

可检验词义区分嵌入、候选集合校准和受控域偏移。这是建议研究，不是已测结果。

依据：Presenter proposals